

文件编号: ITSS-09-02-03

版本: V1.0

西安泽玺信息科技有限公司

银川输油气分公司2026年度桌面及信息网络综合运维 技术服务项目数据清洗策略实施方法

编制人: 丁嘉滢

编制时间: 2026.1.10

审核人: 孙晓玲

审核时间: 2026.1.10

批准人: 冯建东

审批时间: 2026.1.10

修订记录

日期	版本	变更说明	编写人	审核人	批准人
2026. 1. 10	V1. 0	新建文档	丁嘉涛	孙晓玲	冯建东

目录

西安泽玺信息科技有限公司 1

银川输油气分公司2026年度桌面及信息网络综合运维技术服务项目数据清洗策略实施方法 1

1. 文档概述 4

 1.1. 目的 4

 1.2. 适用范围 4

 1.3. 术语定义 5

2. 实施目标 5

 2.1. 数据质量目标 5

 2.2. 业务支撑目标 5

3. 具体实施策略 6

 3.1. 分域清洗实施要点 6

 3.1.1. 运维服务计划数据域 6

 3.1.2. 设备运行状态数据域 6

 3.1.3. 运维技术人员管理数据域 7

 3.1.4. 设备运维数据域 7

 3.1.5. 调度与资源数据域 8

 3.1.6. 费用与结算数据域 8

 3.1.7. 系统日志与接口数据域 9

 3.2. 技术工具与操作流程 9

4. 详细实施步骤 10

 4.1. 第一阶段：规则设计与环境准备（第1-30天） 10

 4.2. 第二阶段：集成联调与试运行（第31-60天） 11

 4.3. 第三阶段：全量上线与监控（第61-75天） 11

 4.4. 第四阶段：验收支持与知识转移（第76-90天） 11

5. 风险管理与质量控制 12

 5.1. 关键风险与应对 12

 5.2. 质量控制活动 12

6. 交付物清单 13

1. 文档概述

1.1. 目的

本文档旨在为“银川输油气分公司2026年度桌面及信息网络综合运维技术服务项目”提供具体、可操作的数据清洗实施方法。本方法严格遵循《数据清洗策略需求分析报告》的业务需求与《数据清洗策略方案》的技术架构，确保数据清洗工作能够高质量、高效率地落地执行，保障桌面及信息网络系统数据的准确性、一致性与时效性。

1.2. 适用范围

本方法适用于本项目所有数据源的清洗实施工作，具体包括但不限于以下七类数据域：

数据域	数据来源	主要问题
运维服务计划数据域	运维申请、运维服务计划、运维工单、计划变更记录	计划与执行脱节、变更记录缺失、运维时段冲突
设备运行状态数据域	设备数据、设备运行记录、设备档案、设备状态信息	设备身份识别错误、状态信息延迟、设备名/编号不一致
运维技术人员管理数据域	运维技术人员档案、资质证书、排班记录、考勤统计	资质过期未更新、证书编号不一致、排班冲突与工时超限
设备运维数据域	设备台账、维修记录、保养计划、故障报修单、巡检记录	设备编码不统一、维修记录缺失、保养计划逾期未执行
调度与资源数据域	运维工具调度记录、运维资源分配、位置信息信息、网络通道状态	资源冲突、调度指令与执行不一致、位置信息编码不统一
费用与结算数据域	运维费收记录、结算凭证、应收账款、收费明细	费率引用错误、计费项目不一致、结算凭证日期混乱
系统日志与接口数据域	应用日志、数据库日志、用户操作日志、接口调用日志	关键告警被淹没、日志格式不统一、接口调用失败未记录

1.3. 术语定义

数据清洗：指按照预定义的业务规则与技术逻辑，对原始数据进行检测、修正、转换或标记，以提升其准确性、完整性、一致性、唯一性与时效性的过程。

数据质量KPI：衡量数据清洗效果的关键量化指标，如准确率、填充率、延迟等。

数据血缘：记录数据从源头到最终形态的完整处理路径与变换关系。

2. 实施目标

2.1. 数据质量目标

通过实施本方法，确保清洗后数据达到以下量化标准：

准确性：核心业务字段值与其真实状态的一致性，核心业务数据准确率不低于95%。

完整性：关键数据采集无缺失，核心业务字段填充率不低于99%。

一致性：同一实体（如设备、运维技术人员、设备）在不同系统中的标识与属性完全统一，主数据一致率达到100%。

时效性：数据从产生到可用的端到端延迟（P95）不超过10秒。

唯一性：业务数据中的重复记录率低于0.1%。

2.2. 业务支撑目标

为运维服务计划编制、资源调度提供准确、及时的设备运行状态和运维技术人员/运维工具可用性数据

为运维作业调度、设备运维管理提供完整、一致的调度指令与执行反馈数据

为运维费收结算、财务对账提供准确、可靠的费收记录和凭证数据

为设备维护、保养计划提供完整、规范的维修和巡检记录

为运维技术人员管理、排班决策提供准确、合规的资质证书和考勤数据

3. 具体实施策略

3.1. 分域清洗实施要点

3.1.1. 运维服务计划数据域

1. 实施要点：

建立运维服务计划与设备运维监控轨迹的关联校验规则，编写SQL脚本定期扫描异常工单（如计划已执行但无对应运维监控轨迹、计划取消但仍占用资源）

对计划变更记录进行完整性校验，确保每次变更均有变更时间、变更原因、操作人记录

检测同一运维技术人员或运维工具在重叠时段内的排班冲突，自动预警并生成冲突报告

建立计划时间逻辑校验规则，确保运维开始时间、结束时间、前后作业衔接顺序合理

2. 技术实现示例（SQL）：

```
sql
-示例：运维人员排班冲突检测脚本
SELECT
    tech_id,
    schedule_date,
    start_time,
    end_time,
    COUNT(*) as conflict_count
FROM ops_schedule_table
WHERE schedule_date = '2026-01-10'
GROUP BY tech_id, schedule_date, start_time, end_time
HAVING COUNT(*) > 1;
```

3.1.2. 设备运行状态数据域

1. 实施要点：

建立设备主数据去重与匹配机制，基于设备识别码、设备资产编号、设备名等关键字段识别并合并重复档案

对设备数据进行异常过滤，剔除数据异常、速度异常（如异常）、时间戳明显错误的

数据
对设备运行状态时间戳进行校验，确保动态记录的时间顺序合理，延迟超过5分钟的数据标记并触发补录

统一设备识别标识规范，确保同一设备在不同数据源（运维监控、运维申请、设备档案）中的编码一致

2. 技术实现示例（SQL）：

```
sql
-示例：设备主数据重复检测脚本
SELECT
    device_code,
    device_name,
    COUNT(*) as duplicate_count
FROM device_master_table
GROUP BY device_code
HAVING COUNT(*) > 1;
```

3.1.3. 运维技术人员管理数据域

1. 实施要点：

建立运维技术人员资质有效期监控机制，临近过期30天自动预警，过期未更新自动标记并限制排班

对排班记录进行冲突检测，确保同一时段不安排多任务，且单日工时不超过规定上限

对运维技术员工号、姓名、证书编号进行一致性校验，与主数据比对，不一致的自动标记

对考勤统计数据与排班计划进行交叉验证，识别异常签到或漏签情况

3.1.4. 设备运维数据域

1. 实施要点：

建立设备主数据统一编码规范，确保同一设备（如服务器、交换机、路由器）在不同系统中的编码一致

对维修记录的关键字段（设备编码、故障现象、维修措施、维修时间、维修人员）进行完整性校验，缺失字段标记并触发补录

建立保养计划执行情况跟踪机制，对逾期未执行的保养计划自动预警并通知责任人

对故障报修单进行分类归集，按故障等级（紧急/重要/一般）自动标记，识别高频故障设备

对巡检记录进行时序校验，确保巡检周期符合预设标准，遗漏巡检自动标记

3.1.5. 调度与资源数据域

1. 实施要点：

建立运维工具与运维任务的资源分配校验规则，检测同一运维工具在重叠时段内的任务冲突

对调度指令与执行反馈进行比对，识别指令未确认、执行偏差等异常情况

统一位置信息编码规范，确保位置信息信息在不同模块中的编码一致，不一致的自动映射

对网络通道状态变更记录进行完整性校验，确保状态变更有时间、原因、操作人记录

3.1.6. 费用与结算数据域

1. 实施要点：

建立费率引用校验规则，自动比对费收记录中的费率与标准费率表，差异超阈值（如>5%）标记

对计费项目进行合理性校验，与设备档案中的参考吨位对比，异常偏差自动预警

建立凭证借贷平衡校验规则，不平凭证自动拦截并写入异常表，通知计费人员

对结算凭证日期进行逻辑校验，确保凭证日期不晚于当前日期，不早于设备作业日期

对收费明细与费收记录进行一致性校验，确保金额匹配、计算正确

2. 技术实现示例（SQL）：

```
sql
-示例：计费项目合理性检测脚本
SELECT
    invoice_id,
    device_id,
    billed_amount,
    reference_value,
    ABS(billed_amount reference_tonnage) / reference_value as
    deviation_rate
FROM billing_record_table
WHERE ABS(billed_amount reference_tonnage) / reference_tonnage >
0.1;
```

3.1.7. 系统日志与接口数据域

1. 实施要点：

制定统一的日志解析规范，使用正则表达式提取时间戳、接口名称、错误码、操作人等关键字段。

建立规则引擎，从海量日志中实时过滤并归类错误、警告等关键事件

对监控接口、数据库连接等关键接口的调用失败、超时等情况进行统计和告警。

对用户异常操作（如多次登录失败、非授权访问尝试、非工作时间敏感操作）进行识别和记录。

3.2. 技术工具与操作流程

1. 批量清洗：

使用Kettle/DataX等ETL工具，对运维服务计划、设备运维、费用结算等核心业务数据进行定时批量清洗。

执行数据标准化、去重、补全等操作，按日批次运行。

2. 实时校验：

在数据接入层部署轻量级校验规则，对实时性要求高的数据（如运维监控动态、运维工单状态变更）进行实时完整性校验。

采用规则引擎（如Drools）管理校验规则，实现规则与代码解耦。

3. 任务调度:

通过**Apache Airflow**进行清洗任务调度，管理依赖关系和执行顺序。

设置失败重试、告警通知机制，确保任务可靠性。

4. 监控看板:

利用**Grafana**配置数据质量KPI看板，实时监控各项指标达成情况。

设置阈值告警，指标异常时通过邮件、企业微信通知相关人员。

5. 规则配置:

清洗规则以**JSON**配置文件形式存储，通过内部管理界面进行发布、更新与回滚。

建立规则版本管理机制，确保规则变更可追溯。

4. 详细实施步骤

4.1. 第一阶段：规则设计与环境准备（第1-30天）

1. 数据源对接:

与各业务系统负责人确认数据接口协议，完成运维服务计划、设备运行状态、运维人员排班、设备运维等模块的接入调试

梳理数据字典，明确各数据域的关键字段和业务规则

2. 规则细化开发:

依据《数据清洗策略实施方案》中的规则设计要点，编写具体的清洗代码与配置文件

为每类清洗规则编写单元测试用例，确保规则正确性

3. 测试环境部署:

搭建与生产环境一致的测试集群，部署清洗程序与相关依赖组件

配置任务调度和监控系统

4. 交付物:

《详细数据清洗规则说明书》

《测试环境部署报告》

清洗规则单元测试用例及结果

4.2. 第二阶段：集成联调与试运行（第31-60天）

1. 模块集成：

将清洗模块与各业务系统进行联调，确保数据通路畅通

验证清洗程序对接入数据的处理效果

2. 试运行与调优：

使用历史数据开展至少15天的试运行，监控清洗效果

根据业务部门（运维调度科、设备管理科、计费科等）的反馈调整规则参数

记录试运行期间的数据质量问题和处理情况

3. 交付物：

《数据清洗模块集成测试报告》

《试运行数据质量分析报告》

试运行期间问题处理记录

4.3. 第三阶段：全量上线与监控（第61-75天）

1. 生产环境部署：

将经测试验证的清洗程序与配置部署至生产环境

执行数据全量清洗，确保历史数据质量

2. 监控体系启用：

全面开启数据质量监控看板与告警，实施7x24小时运行监控

建立数据质量日报机制，每日推送质量报告

3. 交付物：

《生产环境部署手册》

《数据质量监控看板使用指南》

数据质量日报模板

4.4. 第四阶段：验收支持与知识转移（第76-90天）

1. 稳定性运行：

保障清洗系统连续稳定运行，收集验收所需的KPI数据

确保连续15天各项KPI持续达标

2. 文档与培训：

整理全部实施文档，包括设计文档、配置说明、操作手册等

向甲方运维团队提供一次系统性的操作培训，确保知识有效转移

3. 交付物：

《数据清洗系统运维手册》

《培训记录》（含签到表、培训材料）

《最终数据清洗竣工报告》（含KPI达标证明）

5. 风险管理与质量控制

5.1. 关键风险与应对

风险类型	风险描述	应对措施
规则逻辑错误	清洗规则逻辑错误导致数据被错误修改或删除	所有清洗规则上线前必须通过业务逻辑评审与数据样本测试，在测试环境充分验证；变更需走审批流程，并在测试环境验证后方可上线
数据丢失与失真	清洗过程中数据丢失或失真，无法追溯	清洗前对原始数据永久备份；清洗过程中记录完整数据血缘日志，确保任何数据都可追溯还原
系统性能瓶颈	清洗系统成为数据处理瓶颈，影响业务时效	清洗系统需通过至少1.5倍业务峰值压力的性能测试；设置弹性伸缩策略，监控系统负载
业务规则变更	业务规则变化导致清洗规则失效	建立《数据清洗规则变更管理流程》，与业务部门建立沟通机制，及时响应规则变更需求
沟通与协作	与甲方沟通不畅，需求理解偏差	与甲方建立双周例会制度，同步进展、评审报告；使用协同平台管理数据质量问题工单

5.2. 质量控制活动

代码审查：所有清洗脚本与配置变更需经过同级评审。

测试用例：为每类清洗规则编写对应的单元测试与集成测试用例。

质量门禁：在CI/CD流水线中设置质量门禁，测试覆盖率、规则验证通过率不达标则禁止发布。

6. 交付物清单

本实施方法要求产出以下具体交付物，作为工作完成的证据与后续运维的依据：

1. 《详细数据清洗规则说明书》
2. 《数据清洗模块源代码及配置库》
3. 《测试报告》（单元测试、集成测试、性能测试）
4. 《生产环境部署与配置文档》
5. 《数据质量监控看板与告警规则说明》
6. 《数据清洗系统运维手册》
7. 《最终数据清洗竣工报告》（必须附有连续15天KPI达标的数据截图与说明）